OfficeBench — কনে টাস্ক fail হয়

gemma4:31b · বিস্তারিত ব্যর্থতা বিশ্লেষণ · ইংরেজি ও বাংলা রান · ৩০০ সাবটাস্ক

১. কীভাবে মাপা হয় (সংক্ষেপে)

প্রতিটি টাস্কে এজেন্টকে ২০ ধাপ পর্যন্ত কাজ করতে দেওয়া হয়: সে app-এ switch করে, action (JSON) চালায়, ফলাফল দেখে, আবার সিদ্ধান্ত নেয়। শেষে benchmark-এর নিজস্ব স্বয়ংক্রিয় check (যেমন এক্সেলে সেলের মান মেলানো, ফাইল আছে কিনা, ক্যালেন্ডারে overlap আছে কিনা) দিয়ে pass/fail ঠিক হয়। একটি টাস্ক তখনই pass যখন তার সব check পাস করে।

২. সার্বিক ফলাফল

	ইংরেজি	বাংলা
Pass	132 / 300 (44.0%)	103 / 300 (34.3%)
Fail	168 / 300	197 / 300

দোষ কার: ইংরেজি রানে 168টি fail-এর মধ্যে 156 (92%) মডেলের নিজের সীমাবদ্ধতা, মাত্র 12 (7%) benchmark/infra-এর সমস্যা। অর্থাৎ ৪৪% স্কোর মূলত মডেলের আসল সামর্থ্যই দেখায়, benchmark bug-এর কারণে কৃত্রিমভাবে কম নয়।

৩. ব্যর্থতার ধরন — গণনা

ধরন	কী	দোষ	ইংরেজি	বাংলা
A-REASON	ভুল হিসাব / ভুল উত্তর	মডেল	76 (45%)	107 (54%)
A-INTENT	কাজটাই করেনি / ভুল কাজ করেছে	মডেল	27 (16%)	33 (16%)
A-ACTION	আটকে যাওয়া / ২০ ধাপ শেষ	মডেল	52 (30%)	44 (22%)
A-STATE	যা দেখেছে তা উপেক্ষা	মডেল	1 (0%)	0 (0%)
EVAL-MISMATCH	check টাস্কের বাইরে চায়	বেঞ্চমার্ক	11 (6%)	12 (6%)
C-HARNESS	infra/সেভ সমস্যা	বেঞ্চমার্ক	1 (0%)	1 (0%)

৪. প্রতিটি ধরন — ব্যাখ্যা ও বাস্তব উদাহরণ

A-REASON — ভুল হিসাব / ভুল উত্তর [মডেল]

কেন: মডেল ডেটা ঠিকমতো পড়ে, কিন্তু হিসাব/গণনা/যুক্তিতে ভুল করে — তাই লেখা মানটি ভুল। Evaluator হুবহু মান মেলায় (কোনো সহনশীলতা নেই). তাই কাছাকাছি হলেও fail।

> উদাহরণ — 1-5/3 — "বাজেট ৩ বছরে ১০% হারে বাড়লে predicted budget যোগ করো"
> প্রত্যাশিত: 2,729,881 (= 2,051,000 × 1.1^3)। মডেল লিখেছে 2,730,381 — compounding-এ সামান্য ভুল, ৫০০ বেশি। check হুবহু মান চায়, তাই fail।

A-INTENT — কাজটাই করেনি / ভুল কাজ করেছে [মডেল]

কেন: মডেল টাস্ক ভুল বোঝে বা প্রয়োজনীয় ক্রিয়াটি করেই না — যেমন ফাইল সরায় না, নতুন সারি যোগ করে না, অথবা action-টাসককে পরিশ্রম ভেবে শুধু টেকসট উত্তর দেয়।

> উদাহরণ — 1-3/4 — "সব docx/pdf/image ফাইল new_dir ফোল্ডারে সরাও"
> মডেল ফাইলগুলো সরায়নি — new_dir তৈরি হয়নি, data/-তে ফাইল আগের জায়গাতেই। বদলে একটা answer.txt লিখেছে, অর্থাৎ action-টাস্ককে প্রশ্ন ভেবেছে। (1-4/2-তেও "annual bonus 50000" নতুন সারি যোগ করেনি।)

A-ACTION — আটকে যাওয়া / ২০ ধাপ শেষে [মডেলে]

কেন: লম্বা multi-app workflow-এ মডেল পথ হারায় — একই ভুল action বারবার করে আটকে যায় (got_stuck), অথবা ২০ ধাপের মধ্যে কাজ শেষ করতে পারে না।

> উদাহরণ — 3-10/0 — "প্রতিটি প্রাপকের জন্য ফোল্ডার বানাও ও বিল লেখো"
> মডেল একই shell কমান্ড (echo ... > Alice/mobile_bill.txt) বারবার চালিয়ে ২০ ধাপ শেষ করে ফেলে — লম্বা workflow-এ পথ হারিয়ে আটকে যায়।

A-STATE — যা দেখেছে তা উপেক্ষা [মডেলে]

কেন: পরিবেশে দেখো তথ্য অগ্রাহ্য করে — যেমন একটা সময় ইতিমধ্যে দখল করা জেনেও সেখানেই ইভেন্ট বসায় (overlap)।

> উদাহরণ — 1-2/1 — "Bob ও Tom কি একসাথে ডিনার করতে পারে? সময় যোগ করো"
> দুজনেরই ১৮:৩০–১৯:৩০-এ আগে থেকেই "dinner" আছে। মডেল সেটা দেখেও ঠিক ওই সময়েই নতুন ডিনার বসায় overlap no-overlap check fail।

EVAL-MISMATCH — check টাস্কের বাইরে চায় [বেঞ্চমার্ক]

কেন: Benchmark-এর দোষ: টাস্ক শুধু "খুঁজে বের করো" বলে, কিন্তু evaluator একটা নির্দিষ্ট event/keyword দাবি করে যা টাস্ক কখনো তৈরি করতে বলেনি। মডেলের উত্তর যুক্তিসঙ্গত, তবু fail।

> উদাহরণ — 1-2/0 — "Bob ও Tom-এর এক ঘণ্টার মিটিংয়ের সময় খুঁজে বের করো"
> টাস্ক শুধু "খুঁজে বের করতে" বলে; মডেল সঠিক সময় (14:30–15:30) দেয়। কিন্তু evaluator ক্যালেন্ডারে "meeting" keyword-যুক্ত event দাবি করে, যা টাস্ক বানাতে বলেনি fail। এটা benchmark-এর কড়াকড়ি, মডেলের ভুল নয়।

C-HARNESS — infra/সেভ সমস্যা [বেঞ্চমার্ক]

কেন: পরিবেশ/হারনেসের সমস্যা: যেমন Windows-এ colon-যুক্ত ফাইলনাম docker cp করতে না পারা — মডেলের দোষ নয়।

> উদাহরণ — 3-52/0 — "মিটিং এজেন্ডা বানিয়ে ইমেইল করো"
> মডেল একটা ইমেইল ফাইল বানায় যার নামে colon আছে ("Meeting Reminder: Agenda.eml")। Linux-এ বেঁধে, কিন্তু Windows-এ docker cp সেটা কপি করতে পারে না ফলাফল সেভ হয় না। পরিবেশের সীমাবদ্ধতা, মডেলের দোষ নয়।

৫. ইংরেজি বনাম বাংলা — ভাষা কীভাবে ব্যর্থতা বাড়ায়

ক্যাটেগরি	ইংরেজি pass	বাংলা pass	পার্থক্য
১ অ্যাপ (93)	66.7%	45.2%	−21.5%
২ অ্যাপ (95)	54.7%	45.3%	−9.4%
৩ অ্যাপ (112)	16.1%	16.1%	0%
সব মিলিয়ে	44.0%	34.3%	−9.7%

বাংলা নির্দেশনায় একই মডেল বেশি ভুল উত্তর (A-REASON) দেয় — ইংরেজিতে fail-এর ৩৯% ছিল A-REASON, বাংলায় তা ৪৮%। মানে ভাষা বদলালে মূলত মডেলের বোঝা ও হিসাবের ভুল বাড়ে, নতুন ধরনের ব্যর্থতা নয়। লক্ষণীয়: ১-অ্যাপ টাস্কে ভাষার প্রভাব সবচেয়ে বেশি (−21.5%), কিন্তু ৩-অ্যাপ টাস্কে কোনো পার্থক্য নেই (১৬.১% = ১৬.১%)। কারণ ৩-অ্যাপ টাস্ক এমনিতেই মডেলের সাধ্যের বাইরে — সেখানে দু-ভাষাতেই প্রায় সব fail করে, তাই ভাষা আর গুরুত্ব রাখে না। ভাষার প্রভাব সেখানেই দেখা যায় যেখানে মডেলের কাজটা করার সামর্থ্য আছে।

৬. সারসংক্ষেপে

- প্রায় সব ব্যর্থতা (ইংরেজিতে ~94%, বাংলায় ~95%) মডেলের নিজের সীমাবদ্ধতা — ভুল হিসাব, কাজটা না করা, বা লম্বা workflow-এ আটকে যাওয়া।

- মাত্র ~5-6% benchmark/infra-এর সমস্যা (check বশেি চায়, বা Windows সভে সমস্যা)।
- সবচয়েে বড় একক কারণ ভুল মান/হসিাব (A-REASON), এরপর কাজ-না-করা ও আটকে-যাওয়া।
- ৩-অ্যাপ টাস্ক সবচয়েে কঠনি (উভয় ভাষায় ~16%) — লম্বা multi-app planning মডলেরে মূল দুর্বলতা।
- বাংলা নর্দিশেনা performance ~10 পয়ন্টে কমায়, মূলত বোঝা ও হসিাবরে ভুল বাড়য়িে।